


Отчёт: обнаружение аномалий в логах HDFS

1. Постановка задачи


Flexible flow / логи HDFS: encoder (BiLSTM) + IsolationForest на эмбедингах. Оценка на синтетическом датасете с известными метками.

2. Обучение encoder (loss)

encoder / loss



`encoder` / `val\_loss`




3. Визуализации HDFS (test)

hdfs_eval / score_distribution


hdfs_eval/score_distribution

Distribution of anomaly scores



`hdfs\_eval` / `pca\_embeddings`

pca_embeddings




4. Синтетический датасет (ground truth)

Метрики (из эксперимента ClearML)

- **threshold:** -0.0000
- **synth_precision:** 0.955
- **synth_recall:** 0.840
- **synth_f1:** 0.894
- **synth_accuracy:** 0.950
- **synth_roc_auc:** 0.933
- **synth_pr_auc:** 0.900
- **synth_fp:** 4.000
- **synth_fn:** 16.000
- **hdfs_test_anomaly_rate_pct:** 8.500

synthetic_eval / dashboard



Сводка метрик (синтетика, 400 строк: 300 норм / 100 аномалий)

Метрика	Значение	Интерпретация
Accuracy	0.950	Доля верных предсказаний на размеченной синтетике
Precision	0.955	Среди срабатываний «аномалия» — доля реальных аномалий
Recall	0.840	Доля найденных аномалий от всех размеченных
F1	0.894	Баланс precision и recall
ROC-AUC	0.933	Качество ранжирования по score (независимо от порога)
PR-AUC	0.900	То же с учётом дисбаланса классов
Порог (train)	-0.0000	95-й перцентиль anomaly score на HDFS train

	Pred Normal	Pred Anomaly
True Normal	296	4
True Anomaly	16	84

Интерпретация графика synthetic_eval / dashboard

1. Гистограмма anomaly score (норма vs аномалия)

Нормальные строки (синий) в основном **левее порога** — низкий score. Аномалии (красный) смещены **вправо**, но хвосты **пересекаются**: часть аномалий похожа на типичный HDFS, часть нормальных получает повышенный score. Порог (~-0.0000) в целом разделяет классы, но не идеально.

2. Confusion matrix

Около **99% нормальных** распознаны верно; **~84% аномалий** пойманы. Ошибок пропуска (FN) больше, чем ложных тревог (FP): модель **консервативнее** — реже помечает норму как аномалию, но **иногда пропускает** тонкие аномалии.

3. Recall по типу аномалии

Лучше всего детектируются **явные** отклонения (foreign_format, garbage, too_short, warn_panic). Ниже recall у **mutated_normal** — строки, близкие к обычному HDFS. Модель опирается на **структуру и лексику** лога, а не на единичный «плохой» токен.

Интерпретация графиков HDFS (test)

hdfs_eval / score_distribution — распределение score на train/test; красная линия — порог. Большинство test-строк ниже порога (норма); хвост — кандидаты в аномалии (~5% по design contamination=0.05).

hdfs_eval / pca_embeddings — 2D-проекция эмбедингов encoder. Аномалии (красные) частично выделяются в пространстве признаков, но есть **перекрывтие** с нормой — это объясняет ошибки на «тонких» аномалиях.

5. Общая оценка качества модели

Итог: модель показала себя хорошо для учебной unsupervised-постановки.

1. **Encoder (BiLSTM) + IsolationForest** на эмбедингах даёт **устойчивое** разделение нормы и аномалий на контролируемом синтетическом наборе ($F1 \approx 0.894$, $ROC-AUC \approx 0.933$).
2. Подход **работает** для «очевидных» аномалий (чужой формат, мусор, WARN/panic, слишком короткие строки).
3. **Слабые места:** обучение без разметки только на HDFS; порог с train; пропуски на **mutated_normal** и пограничные FP на нормальных логах.
4. Для промышленного использования нужна **валидация на реальных инцидентах** и настройка порога под цель (минимум FP vs минимум FN).

6. Выводы

- Пайплайн (нормализация → encoder → IsolationForest) **пригоден** для первичного скрининга подозрительных логов HDFS.
- Синтетическая оценка с известными метками подтверждает **высокое качество ранжирования** (ROC-AUC) и **практичный** баланс precision/recall.